

Laporan Ujian Akhir Semester
Optimasi Machine Learning Dalam Klasifikasi Phishing Url



Dosen Pengampu :

Junta Zeniarja, M.Kom

Disusun oleh:

Nama: Mayolus Gavin Alphared

NIM : A11.2024.15574

Kelompok : A11.4401

**PROGRAM STUDI TEKNIK INFORMATIKA FAKULTAS ILMU
KOMPUTER UNIVERSITAS DIAN NUSWANTORO SEMARANG 2026**

BAB I

Pendahuluan

1.1 Latar Belakang Masalah

Perkembangan teknologi informasi dan kapasitas komputasi yang bergerak sangat masif pada era digital ini memicu para pelaku kejahatan siber (*attackers*) untuk terus memodifikasi taktik serangan mereka. Menurut Rawla et al. (2025), para penyerang kini gencar memunculkan teknik-teknik baru maupun memodifikasi metode tradisional guna menembus sistem keamanan dan mencuri data rahasia demi keuntungan sepihak. Salah satu jenis ancaman siber yang paling konsisten berada dalam tren berbahaya dan menjadi perhatian global adalah serangan *phishing*. Hal ini sejalan dengan pandangan Moorthy & Pabitha (2020) yang menyatakan bahwa *phishing* merupakan kejahatan rekayasa sosial (*social engineering*) berbahaya yang bertujuan untuk mencuri informasi pribadi pengguna internet melalui pengiriman pesan siber palsu.

Mekanisme pertahanan konvensional berbasis daftar hitam (*blacklist filtering*) terbukti menghadapi kendala besar karena lambat mengidentifikasi domain baru (*zero-day attacks*). Berdasarkan riset Moorthy & Pabitha (2020), daur hidup sebuah URL *phishing* rata-rata hanya bertahan sekitar 3.1 hari sebelum dinonaktifkan, sehingga pendekatan daftar putih (*whitelist*) pun tidak lagi efisien akibat laju pertumbuhan situs web yang terlalu masif. Dalam situasi ini, pendekatan berbasis *machine learning* dan *supervised learning* menjadi instrumen pertahanan proaktif yang sangat krusial. Dengan melatih model pada dataset berlabel, karakteristik anomali leksikal string URL dapat diekstrak dan diklasifikasikan secara otomatis untuk mendeteksi ancaman secara instan tanpa perlu mengunduh konten web yang berbahaya.

1.2 Tujuan Proyek

Proyek ini bertujuan untuk:

- 1) Menerapkan supervised classification (KNN, Naive Bayes, SVM) untuk klasifikasi URL phishing. Membandingkan akurasi, presisi, dan daya generalisasi dari tiga algoritma klasifikasi populer (KNN, Decision Tree, dan Naive Bayes)
- 2) Melakukan optimasi hyperparameter tuning, class imbalance handling, cross-validation, dan feature selection
- 3) Mengimplementasikan model ke aplikasi web Streamlit
- 4) Menganalisis performa komparatif dan menentukan model terbaik.

BAB II

Studi Literatur

2.1 Mini Review Paper Rujuan Utama

Komponen	Uraian
Penulis	Anish Rawla, Shreya Singh, Md Daniyal, Preeti Dubey
Tahun	2025
Jurnal	<i>Procedia Computer Science</i> (Elsevier)
DOI	10.1016/j.procs.2025.04.003
Judul Paper	Detection of Phishing Attacks in PhiUSIIL Dataset using Deep Learning
Dataset	UCI PhiUSIIL Phishing URL Dataset (235.795 instansi, 56 fitur)
Metode	Penerapan model <i>Fully Connected Neural Network</i> (FCNN) yang dipasangkan dengan pembersihan data (<i>feature dropping</i>), standardisasi skala melalui pembagian rentang Min-Max, serta oversampling SMOTE
Metrik Evaluasi	<i>Precision</i> , <i>Recall</i> , <i>F1-Measure</i> , dan <i>Accuracy</i>
Hasil Utama	Arsitektur FCNN mencatatkan akurasi puncak 99.38%, berhasil melampaui keunggulan model pembanding konvensional berbasis <i>Random Forest</i> (98.69%), <i>Decision Tree</i> (98.38%), dan SVM (97.79%)
Relevansi terhadap Project	Paper ini memandu pemilihan dataset PhiUSIIL sebagai referensi data siber modern era 2024–2026 serta menjustifikasi penghapusan kolom teks redundan pembawa kebocoran informasi (<i>data leakage</i>)

2.2 Sintesis Metode Optimasi yang Diadaptasi

Berdasarkan bukti empiris dari paper-paper di atas, project ini menurunkan lima strategi optimasi berikut untuk diuji pada ketiga algoritma wajib (KNN, Naive Bayes, SVM):

- 1) Hyperparameter Tuning (GridSearchCV). Al Hakim et al. (2026) menunjukkan bahwa Grid Search mampu meningkatkan akurasi model secara signifikan. Strategi ini diadopsi untuk mencari kombinasi parameter `n_neighbors`/metric pada KNN, `var_smoothing` pada Naive Bayes, serta `kernel/C/gamma` pada SVM.
- 2) Stratified k-Fold Cross-Validation (5-fold). Ini digunakan untuk mengurangi bias pembagian data dan memastikan setiap fold merepresentasikan proporsi kelas yang sama.
- 3) Feature Selection berbasis Mutual Information. Diadopsi dari pendekatan Malik et al. (2025) untuk memilih fitur URL paling informatif dan mengurangi risiko overfitting.

- 4) Class Imbalance Handling (SMOTE). Synthetic Minority Over-sampling Technique diterapkan untuk menyeimbangkan distribusi kelas Legitimate dan Phishing pada data latih.
- 5) Metric Selection berbasis Macro-F1. Macro-F1 dipilih sebagai metrik evaluasi utama karena lebih representatif dibanding accuracy pada dataset dengan sedikit ketidakseimbangan kelas, didukung balanced accuracy dan ROC-AUC sebagai metrik sekunder.

BAB III

Dataset dan Data Dictionary

3.1 Sumber Data

Dataset yang digunakan adalah PhiUSIIL Phishing URL Dataset yang bersumber dari UCI Machine Learning Repository, terdiri dari 235.795 baris dan 56 kolom. Target klasifikasi adalah kolom label (0 = Legitimate, 1 = Phishing).

3.2 Data Dictionary

Dataset terdiri dari dua kelompok fitur, yaitu fitur URL-Based (22 fitur, misalnya URLLength, DomainLength, IsDomainIP, URLSimilarityIndex) dan fitur Content-Based (32 fitur, misalnya LineOfCode, NoOfImage, NoOfJS). Lima kolom non-numerik (FILENAME, URL, Domain, TLD, Title) dihapus karena berpotensi menyebabkan data leakage jika ikut diproses model. Project ini memilih 22 fitur URL-Based sebagai fitur prediksi utama karena dapat diekstrak langsung dari string URL tanpa perlu mengunduh konten halaman, sehingga cocok untuk prediksi instan pada aplikasi.

Data dictionary lengkap tersedia pada file data_dictionary.md yang mencakup deskripsi seluruh 56 kolom dataset beserta tipe data dan penjelasan masing-masing fitur.

3.3 Definisi Target Klasifikasi

Target klasifikasi bersifat biner dan kategorikal: label 0 (Legitimate) dan label 1 (Phishing). Karena tersedia label ground truth pada seluruh data, kasus ini termasuk supervised classification, bukan clustering maupun regresi.

3.4 Etika dan Privasi Data

- 1) Anonimitas Data: Dataset PhiUSIIL yang diakuisisi dari UCI Repository merupakan data publik yang telah dianonimkan, tidak memuat riwayat aktivitas privat, alamat IP spesifik individu, maupun identitas sensitif korban.
- 2) Keamanan Komputasi Lokal: String tautan URL yang diuji melalui dashboard Streamlit diproses secara on-the-fly pada memori lokal dan tidak direkam ke dalam basis data eksternal mana pun.

- 3) Fungsi Pendukung Keputusan: Aplikasi ini diposisikan murni sebagai decision support system siber untuk membantu deteksi dini, bukan instrumen pemblokiran mutlak yang mengabaikan verifikasi lanjutan.

3.5 Batasan Penggunaan Data dan Model

Model tidak boleh digunakan sebagai satu-satunya lapisan keamanan siber dan tidak bertanggung jawab atas kerugian yang timbul dari keputusan yang diambil berdasarkan hasil prediksi. Model juga tidak dirancang untuk mendeteksi jenis serangan siber lain di luar phishing berbasis URL

BAB IV

Audit Data dan Preprocessing

4.1 Audit Kualitas Data Awal

Hasil audit menunjukkan jumlah baris 235.795 dan jumlah kolom 56. Distribusi target: Phishing = 134.850 (57,2%), Legitimate = 100.945 (42,8%), dengan rasio imbalance 1,34. Tidak ditemukan missing values maupun data duplikat. Outlier terdeteksi pada 38 kolom menggunakan metode IQR, dengan kolom yang memiliki proporsi outlier terbanyak yaitu NoOfSubDomain (24,34%) dan NoOfDegitsInURL (21,82%).



```
=====
AUDIT DATA
=====

Missing values total: 0
Tidak ada missing values!

Data duplikat: 0

Baris mengandung outlier: 209188

Outlier per kolom (top 10):
NoOfSubDomain      57389
Pay                55885
NoOfDegitsInURL    51461
DegitRatioInURL    51461
IsHTTPS            51256
NoOfEmptyRef       38885
NoOfiFrame         34441
HasTitle           32714
NoOfURLRedirect    31464
Bank               29967
dtype: int64
```



4.2 Pembersihan Duplikat dan Outlier

Karena tidak ditemukan data duplikat, tahap ini difokuskan pada penanganan outlier menggunakan metode IQR clipping agar nilai ekstrem pada fitur numerik tidak mendominasi proses pelatihan model, khususnya untuk algoritma yang sensitif terhadap skala dan jarak seperti KNN dan SVM.

4.3 Seleksi dan Reduksi Fitur

Pipeline preprocessing yang diterapkan meliputi: (1) sampling 15.000 baris secara stratified agar proses eksperimen lebih efisien tanpa mengubah proporsi kelas; (2) penghapusan kolom non-numerik (FILENAME, URL, Domain, TLD, Title) yang berpotensi menyebabkan data leakage; (3) seleksi 22 fitur URL-Based untuk mendukung prediksi instan; (4) outlier handling dengan IQR clipping; (5) standarisasi menggunakan StandardScaler; dan (6) stratified train-test split dengan rasio 80:20. Hasil akhir pipeline ini menghasilkan 11.992 data latih dan 2.999 data uji.


4.4 Pemeriksaan Class Imbalance

Rasio imbalance sebesar 1,34 tergolong ringan, namun tetap ditangani menggunakan SMOTE (Synthetic Minority Over-sampling Technique) pada data latih agar model tidak bias terhadap kelas mayoritas (Phishing), sesuai dengan strategi optimasi yang disusun pada BAB II.



4.5 Normalisasi (Scaling)

Sebelum preprocessing, fitur numerik memiliki rentang nilai yang sangat bervariasi, misalnya URLLength (6–1724) dan DomainLength (3–124). Setelah StandardScaler diterapkan, seluruh fitur memiliki mean mendekati 0 dan standar deviasi 1. Sebagai contoh, URLLength yang semula memiliki mean 50,14 dan std 102,50 berubah menjadi mean 0,00 dan std 1,00 setelah scaling. Transformasi ini penting bagi algoritma yang sensitif terhadap skala fitur seperti KNN (berbasis jarak Euclidean) dan SVM (mencari hyperplane optimal), karena tanpa scaling, fitur dengan rentang nilai besar dapat mendominasi perhitungan jarak.



4.6 Pemeriksaan Potensi Data Leakage

Data leakage adalah kondisi ketika informasi dari data uji secara tidak sengaja ikut digunakan dalam proses training, sehingga evaluasi model menjadi tidak realistis. Empat langkah pencegahan leakage diterapkan pada project ini:

- 1) Kolom identitas URL (FILENAME, URL, Domain, TLD, Title) dihapus sebelum data displit, bukan sesudahnya.
- 2) StandardScaler menggunakan `fit_transform` hanya pada data latih, dan `transform` saja pada data uji, sehingga statistik scaling murni berasal dari data latih.
- 3) Feature selection berbasis Mutual Information dihitung hanya berdasarkan data latih.
- 4) Stratified split memastikan proporsi kelas yang sama pada data latih dan data uji, sehingga mencegah bias distribusi.


BAB V DESAIN EKSPERIMEN

5.1 Strategi Pembagian Data (Train-Test Split)

Data dibagi menggunakan stratified split dengan rasio 80:20, menghasilkan 11.992 data latih dan 2.999 data uji, sehingga proporsi kelas Legitimate dan Phishing tetap terjaga pada kedua subset.

5.2 Algoritma Baseline vs Algoritma yang Dioptimasi

Tiga algoritma wajib diuji dalam dua skenario, yaitu baseline (parameter default) dan optimized (setelah hyperparameter tuning). Parameter awal baseline: KNN (`n_neighbors=5`, `weights='uniform'`, `metric='minkowski'`), Naive Bayes (GaussianNB default, `var_smoothing=1e-9`), dan SVM (`kernel='rbf'`, `C=1.0`, `gamma='scale'`). Sebagai pembanding minimal, DummyClassifier dengan strategi `most_frequent` turut disertakan dan menghasilkan akurasi 57,2% — sesuai proporsi kelas mayoritas — yang wajib dilampaui oleh seluruh model agar dapat dikatakan benar-benar belajar dari data.




5.3 Metrik Evaluasi Utama

Metrik evaluasi yang digunakan meliputi Accuracy, Precision, Recall, F1-Score, Macro-F1, dan Balanced Accuracy. Macro-F1 dijadikan metrik utama karena lebih representatif untuk dataset dengan sedikit ketidakseimbangan kelas dibandingkan accuracy semata.

BAB VI DESAIN EKSPERIMEN

6.1 Hasil Baseline


Model	Accuracy	Precision	Recall	F1-Score	Macro-F1	Bal. Acc
KNN	0.9963	0.9942	0.9994	0.9968	0.9962	0.9958
Naive Bayes	0.9987	0.9988	0.9988	0.9988	0.9986	0.9986
SVM	0.9993	0.9988	1.0000	0.9994	0.9993	0.9992



Ketiga model baseline menunjukkan akurasi di atas 99,6% dan seluruhnya melampaui dummy baseline (57,2%). SVM menjadi baseline terbaik dengan akurasi 99,93% dan macro-F1 0,9993.

6.2 Perbandingan Baseline vs Optimized

Strategi optimasi yang diterapkan meliputi hyperparameter tuning dengan GridSearchCV (scoring macro-F1), stratified 5-fold cross-validation, SMOTE untuk class imbalance, dan feature selection berbasis Mutual Information (top-30 fitur). Grid pencarian parameter: KNN — $n_neighbors=[3,5,7,9,11]$, $weights=[uniform, distance]$, $metric=[euclidean, manhattan]$; Naive Bayes — $var_smoothing=[1e-11 \dots 1e-5]$; SVM — $C=[0.1,1,10]$, $gamma=[scale, auto]$, $kernel=[rbf, linear]$.




6.3 Analisis Stabilitas Model

Uji stabilitas melalui 5-fold cross-validation menunjukkan SVM memiliki standar deviasi macro-F1 paling rendah (0,0012), yang mengindikasikan konsistensi performa paling tinggi di antara ketiga model. Sebagai pembandingan, KNN memiliki $std=0,0021$ dan Naive Bayes memiliki $std=0,0018$.

6.4 Error Analysis

Error analysis dilakukan pada model optimized terhadap 2.999 sampel data uji. KNN menghasilkan 5 kesalahan (error rate 0,17%), seluruhnya berupa false positive (URL legitimate diprediksi sebagai phishing). Naive Bayes menghasilkan 3 kesalahan (0,10%), terdiri dari 2 false positive dan 1 false negative. SVM menghasilkan 2 kesalahan (0,07%), keduanya false positive. Pola penting yang ditemukan adalah seluruh kesalahan false positive terjadi pada URL dengan karakteristik yang mendekati phishing, misalnya URL panjang, banyak subdomain, dan

mengandung karakter obfuscated. Analisis fitur pembeda menunjukkan URLSimilarityIndex, CharContinuationRate, dan TLDLength sebagai kontributor utama kesalahan.



BAB VII

Pembahasan

7.1 Model Terbaik

Model terbaik pada project ini adalah SVM Optimized (kernel='linear', C=1, gamma='scale') dengan akurasi 99,93%, macro-F1 0,9993, dan balanced accuracy 0,9992.

7.2 Alasan Akademik

- 1) Performa tertinggi secara konsisten di seluruh metrik evaluasi dibandingkan KNN dan Naive Bayes.
- 2) Stabilitas cross-validation score paling konsisten, ditunjukkan oleh standar deviasi macro-F1 terendah.
- 3) Kernel linear pada SVM lebih interpretable dan efisien secara komputasi dibandingkan kernel non-linear.
- 4) Kesiapan untuk deployment karena waktu training yang relatif rendah dibandingkan model deep learning seperti pada paper acuan.

7.3 Diskusi Kritis Bias Dataset

Mayoritas URL legitimate dalam dataset menggunakan protokol HTTPS, sehingga model cenderung mengasosiasikan HTTPS dengan kelas legitimate dan HTTP dengan kelas phishing. Padahal dalam konteks nyata, masih banyak situs legitimate yang menggunakan HTTP, sehingga hal ini merupakan bias historis dataset yang perlu diwaspadai agar model tidak salah menggeneralisasi. Solusi yang direkomendasikan adalah menambahkan data augmentasi berupa URL legitimate berbasis HTTP.

7.4 Implikasi bagi Pengguna

Hasil ini menunjukkan bahwa model machine learning klasik seperti SVM masih sangat kompetitif untuk deteksi phishing berbasis fitur URL, sejalan dengan temuan pada paper acuan bahwa pendekatan berbasis fitur yang ringkas mampu memberikan akurasi tinggi tanpa memerlukan arsitektur deep learning yang kompleks, sehingga lebih mudah diimplementasikan pada aplikasi prediksi instan berbasis Streamlit.

BAB VIII

DESAIN APLIKASI


8.1 Arsitektur Backend


- 1) `src/ml_core.py` — fungsi inti (audit data, preprocessing, training, evaluasi, error analysis).
- 2) `src/train.py` — pipeline training end-to-end (load data → audit → preprocess → baseline → optimasi → evaluasi → simpan model).
- 3) `src/predict.py` — inferensi model untuk prediksi data baru.
- 4) `app_streamlit.py` — antarmuka pengguna Streamlit dengan 5 halaman. Model dan scaler disimpan dalam format `.joblib` untuk keperluan deployment.

8.2 Alur UI/UX Aplikasi

- 1) Dashboard Data — menampilkan ringkasan dataset, distribusi target, dan informasi hasil audit.
- 2) Prediksi URL — input berupa URL mentah (fitur diekstrak otomatis) atau form manual 22 fitur, dengan hasil ditampilkan melalui gauge chart risiko phishing.
- 3) Perbandingan Model — menampilkan tabel metrik, bar chart, dan radar chart antar model.
- 4) Visualisasi & Error Analysis — menampilkan distribusi fitur, korelasi antar fitur, dan analisis kesalahan.
- 5) Tentang — menjelaskan metodologi, etika penggunaan, dan disclaimer decision support.

8.3 Screenshoot aplikasi





8.4 Cara Menjalankan Program

Aplikasi dapat dijalankan dengan menginstal seluruh dependensi pada requirements.txt, kemudian melatih model dan menjalankan antarmuka Streamlit dengan langkah berikut:

1. `pip install -r requirements.txt`
2. `python src/train.py`
3. `streamlit run app_streamlit.py`
4. Buka browser di `http://localhost:8501`

8.5 Etika Aplikasi

Aplikasi menampilkan disclaimer bahwa hasil prediksi bersifat decision support dan bukan keputusan keamanan final. Data URL yang dimasukkan pengguna tidak disimpan, dan model tidak boleh dijadikan satu-satunya lapisan keamanan siber.

BAB IX

Kesimpulan dan Rekomendasi

9.1 Kesimpulan (Capaian Outcome)

- 1) Problem framing klasifikasi phishing URL sebagai supervised classification telah didefinisikan dengan jelas, didukung oleh mini-review paper acuan (Rawla et al., 2025) yang menggunakan dataset PhiUSIIL yang sama.
- 2) Dataset PhiUSIIL berhasil diaudit dan diproses melalui pipeline preprocessing yang reproducible, termasuk pencegahan data leakage dan penanganan outlier.
- 3) Ketiga model baseline (KNN, Naive Bayes, SVM) menunjukkan performa sangat baik dengan akurasi di atas 99,6%.
- 4) Optimasi dengan GridSearchCV, SMOTE, dan feature selection berhasil meningkatkan performa KNN dan Naive Bayes, sementara SVM tetap stabil pada performa tertingginya.
- 5) SVM Optimized terpilih sebagai model terbaik (akurasi 99,93%, macro-F1 0,9993) dan diimplementasikan pada aplikasi Streamlit untuk digunakan pengguna non-teknis.

9.2 Keterbatasan Penelitian

- 1) Dataset bersumber dari satu repositori sehingga generalisasi model terhadap domain URL di luar distribusi data belum teruji.
- 2) Terdapat bias korelasi protokol HTTP/HTTPS pada dataset yang berpotensi memengaruhi generalisasi model di dunia nyata.
- 3) Model hanya menggunakan fitur statis dari string URL tanpa analisis konten HTML secara langsung.
- 4) Belum tersedia mekanisme feedback loop untuk pembaruan atau retraining model secara berkelanjutan.

9.3 Rekomendasi Pengembangan

- 1) Mengintegrasikan sumber data tambahan (multi-source dataset) agar model lebih general terhadap variasi URL phishing terbaru.
- 2) Menambahkan algoritma ensemble (Random Forest, XGBoost) maupun pendekatan deep learning sebagaimana pada paper acuan sebagai pembanding lanjutan.
- 3) Melakukan deployment aplikasi menggunakan Docker dan FastAPI agar lebih scalable dan dapat diakses secara daring.
- 4) Menambahkan fitur explainability (SHAP/LIME) agar prediksi model lebih dapat dipertanggungjawabkan secara akademik dan etis.
- 5) Menyediakan mekanisme feedback pengguna untuk mendukung retraining model secara berkala.

Lampiran

Rawla, A., Singh, S., Daniyal, M., & Dubey, P. (2025). Detection of Phishing Attacks in PhiUSIIL Dataset using Deep Learning. *Procedia Computer Science*, 259, 543–552.

<https://www.sciencedirect.com/science/article/pii/S1877050925011007>

UCI Machine Learning Repository. (2024). PhiUSIIL Phishing URL Dataset.

<https://archive.ics.uci.edu/dataset/967/phiusiil+phishing+url+dataset>

Repository Github.

<https://github.com/Alphared26/uas-ml-phishing-url/tree/main>

Video Youtube Presentasi

https://youtu.be/_5yuZSNSzMY